O meu dado, com rigor — gabarito do caminho padrão (AMS)

> **Gabarito do projeto padrão, para conferir.** É o `relatorio-dado.md` do Laboratório 03 (`D3-03`) respondido para o AMS, cujo conjunto de dados é o *AI4I 2020* completo da D1 (10 000 linhas, 14 colunas). As medidas abaixo são a saída do `medidas.py` sobre esse arquivo; as tabelas de extremos, que o programa lista linha a linha, estão resumidas. Quem rodar sobre a amostra de 200 linhas da D1 terá outros números e as mesmas decisões.

Medidas por variável (saída do `medidas.py`)

variável	n	faltantes	média	mediana	desvio	Q1	Q3	mín	máx
Air temperature [K]	10000	0	300.00	300.10	2.00	298.30	301.50	295.30	304.50
Process temperature [K]	10000	0	310.01	310.10	1.48	308.80	311.10	305.70	313.80
Rotational speed [rpm]	10000	0	1538.78	1503.00	179.28	1423.00	1612.00	1168.00	2886.00
Torque [Nm]	10000	0	39.99	40.10	9.97	33.20	46.80	3.80	76.60
Tool wear [min]	10000	0	107.95	108.00	63.65	53.00	162.00	0.00	253.00
Machine failure	10000	0	0.0339	0	0.1810	0	0	0	1

`UDI` e `Product ID` são identificadores; `Type` é categórica (L 6 000, M 2 997, H 1 003). Os cinco modos de falha (TWF, HDF, PWF, OSF, RNF) são binários, como o rótulo.

Extremos marcados, e a decisão sobre cada grupo

O programa marcou **1 199 extremos**. A decisão, grupo a grupo:

`Rotational speed [rpm]` — 418 extremos, acima de 1 895,5 rpm. R: MANTER TODOS. São rotações altas reais do processo, não erro de sensor: a máquina opera numa faixa de potência, e rotação alta vem com torque baixo. Nesses 418 a taxa de falha é 8,4%, contra 3,4% no conjunto: a cauda é justamente onde a falha de potência (PWF, 31 dos 418) mora. Remover seria apagar parte do fenômeno que o agente precisa reconhecer.

`Torque [Nm]` — 69 extremos, abaixo de 12,8 ou acima de 67,2 Nm. R: MANTER TODOS. 62 dos 69 são falhas, de potência ou de sobrecarga. É o caso mais claro do laboratório: o extremo não é ruído, é o sinal.

`Machine failure` e os cinco modos — 339 extremos no rótulo, e 46, 115, 95, 98 e 19 nos modos. R: NÃO SÃO EXTREMOS, E NADA SAI. A regra de 1,5 × a caixa não se aplica a variável binária rara: com 3,4% de uns, o primeiro e o terceiro quartis são zero, a caixa tem largura zero, e todo "1" cai fora dela. Os 339 "extremos" do rótulo são **todas as falhas do conjunto**. Remover os extremos aqui apagaria o sinal inteiro e

deixaria um conjunto em que nenhuma máquina falha. A decisão registrada: a regra de extremos vale para as variáveis contínuas; nas binárias, o que se examina é a consistência (abaixo).

Faltantes

Nenhuma variável tem valores faltantes. A falta que existe no AMS é de outro tipo, e não aparece como célula vazia: **27 registros com rótulo inconsistente**. São 9 com `Machine failure = 1` e nenhum modo marcado, e 18 com RNF marcado e `Machine failure = 0`. É informação faltante sobre a causa, não sobre o valor. A decisão: manter os 27, marcá-los, e a D5 decide se confia no rótulo ou nos modos (a D1 já tinha pedido essa política ao agente).

As quatro perguntas do slide 29

1. Média e mediana se separam em alguma variável? Em qual? R: Em `Rotational speed`: média 1 538,8 e mediana 1 503,0, com assimetria positiva (a cauda das rotações altas puxa a média). Nas temperaturas, no torque e no desgaste, média e mediana praticamente coincidem. No rótulo, a média (0,0339) é a taxa de falha, e a mediana (0) não diz nada: em variável binária rara, a mediana esconde o fenômeno.

2. Quantos extremos foram marcados, e quantos você decidiu manter? R: 1 199 marcados, 1 199 mantidos. 487 são das duas variáveis contínuas (rotação e torque), mantidos por serem o sinal; os outros 712 são "extremos" de variáveis binárias, onde a regra não se aplica.

3. Algum faltante parece do terceiro mecanismo? R: Não há célula faltante. Os 27 registros inconsistentes são a falta que importa, e o mecanismo mais provável é o condicional: o registro do modo depende de como a falha foi classificada, e a falha aleatória (RNF) foi anotada à parte do rótulo geral.

4. O que a análise da D1 não tinha visto? R: Que a regra de extremos, aplicada sem olhar o tipo da variável, manda remover todas as falhas. A D1 tinha visto que a falha é rara (3,4%); o lab-03 mostra o que a raridade faz com uma ferramenta estatística correta usada no lugar errado.

Comparação com a análise exploratória da D1

R: A D1 concluiu que falha é evento raro e multicausal, e que 27 registros são inconsistentes. O lab-03 acrescenta duas decisões escritas que a D5 vai herdar: os extremos de rotação e de torque ficam, porque é neles que as falhas de potência e de sobrecarga se concentram; e o rótulo inconsistente fica marcado, não removido. O conjunto que a D5 recebe é o mesmo, com as decisões registradas.

Erro previsível. Remover os 1 199 extremos por obediência à regra, ou só os do rótulo, sem perceber que eles são as falhas. É o erro mais caro do laboratório no AMS: o modelo da D5 treinaria num conjunto sem nenhuma falha, e não haveria nada a aprender.

O que transferir para o seu domínio. Antes de decidir sobre um extremo, pergunte de que tipo é a variável e se o extremo é o fenômeno que você quer prever. A regra de 1,5 × a caixa é para variáveis contínuas.